

Input-aware 백도어 공격 / 방어 실험 보고서

대상 공격: Input-aware Dynamic Backdoor Attack (Nguyen & Tran, NeurIPS 2020) 데이터셋 / 모델: CIFAR-10 / PreAct-ResNet18 평가 방어: FT, NAD, ANP, ABL, NC (5종) 비교 대상: WaNet (별도 보고서) — 동일 저자의 후속 공격, 동일 실험 셋팅

0. 한눈에 보기

단계	clean ACC	ASR	RA	WaNet과 비교
공격 (Input-aware)	0.9106	0.9449	0.0524	거의 동일 (WaNet 0.914/0.951)
+ FT 방어	0.9265	0.2127	0.744	약간 더 견딤 (WaNet 0.17)
+ NAD 방어	0.9260	0.5473	0.432	훨씬 강하게 견딤 (WaNet 0.087)
+ ANP 방어 (기본)	0.8634	0.0050	0.844	거의 동일 (WaNet 0.010)
+ ANP (Pareto knee t=0.45)	0.9102	0.0109	0.885	knee도 거의 동일
+ ABL 방어 (소규모)	0.5964	0.9899	0.007	완전 실패 (WaNet 0.84/0.59)
+ NC 방어	0.9120	0.9844	0.015	둘 다 실패

핵심: - Input-aware는 WaNet과 헤드라인 ACC/ASR이 거의 동일하나 **방어 견딤 정도가 다름** - NAD에 훨씬 강하게 견딤 (ASR 6배), ABL에 더 치명적으로 깨짐 (model collapse) - ANP / NC에 대한 반응은 WaNet과 거의 동일 — 두 attack의 공통 특성

1. 환경

WaNet 보고서와 동일 환경 (별도 보고서 §1 참조). Windows + RTX 5070 Ti + Python 3.10 + PyTorch 2.11+cu128.

2. Input-aware 공격 원리

Input-aware는 **입력별로 다른 트리거**를 생성기 네트워크가 생성한다. WaNet의 고정 워핑과 정반대 설계.

	Input-aware	WaNet
트리거	per-sample, generator가 합성	per-network, 고정 워핑
트리거 결정	입력 이미지에 의존	학습 시작 시 고정
Cross sample	있음 (디코이)	있음
저자	Nguyen & Tran	Nguyen & Tran
발표	NeurIPS 2020	ICLR 2021

학습 구조

- **stage1 (clean training)**: 25 epochs 동안 generator/mask 없이 backbone classifier C만 학습 → 좋은 초기 표현 확보
- **stage2 (backdoor training)**: 100 epochs 동안 세 네트워크를 동시 학습
- Generator G: trigger 이미지 합성 (입력 의존)
- Mask M: trigger의 spatial location 결정
- Classifier C: clean + bd + cross 샘플 학습

핵심 손실

- `loss_div` : G가 입력에 따라 *다양한* 트리거를 생성하도록 강제 (per-image diversity)
- `loss_norm` : G가 만든 trigger의 spatial norm 제한 (imperceptibility)
- `bd_loss`: classifier가 trigger를 target으로 분류
- `cross_loss`: classifier가 cross sample (다른 입력의 trigger를 갖다 붙임)을 *원래 라벨*로 분류 → "특정 입력-트리거 쌍"만 백도어로 작동하게 만드는 lock-in

기본 하이퍼파라미터

파라미터	값	의미
<code>pratio</code>	0.1	poison ratio
<code>attack_target</code>	0 (airplane)	target class
<code>mask_density</code>	0.032	mask 영역 비율 (전체 픽셀의 3.2%)
<code>lambda_div</code>	1	diversity loss 가중치
<code>lambda_norm</code>	100	trigger norm penalty 가중치
<code>clean_train_epochs</code>	25	stage1 길이

3. 실험 1: Input-aware 공격 학습

3.1 학습 셋팅


- 100 epochs (WaNet 메인 run과 동일), batch_size 256, AMP, SGD
- stage1 25 epoch (clean) + stage2 100 epoch (bd 학습)
- 학습 시간: 약 100분 (RTX 5070 Ti)

3.2 결과 (epoch 99 / 마지막)

지표	값
test_acc (clean)	0.9106
test_asr	0.9449
test_ra	0.0524
test_cross_acc	0.8440
max test_asr (학습 도중 피크)	0.9953

3.3 비교 시각화 — clean vs Input-aware 백도어

3행 × 8열: (1) clean / (2) Input-aware 백도어(bd, label은 모두 target=0으로 변경됨) / (3) cross-noise. 저장된 변형 이미지를 인덱스로 원본 CIFAR-10 테스트셋과 매칭해 나란히 비교한다.



관찰 포인트 (WaNet 보고서 §3.5의 동일 시각화와 결정적 차이): - 2행(bd)에 눈에 보이는 작은 **colored line/dot 패턴** 존재 — 빨강/민트(cyan)/검정/노랑 색이 좁은 영역(가장자리 또는 객체 위)에 집중. WaNet의 bd는 clean과 시각적 구별 불가였던 것과 대조 - 이 colored 패턴이 **Input-aware의 실제 트리거**다. Generator G가 입력마다 다른 패턴을 합성하고 Mask M이 spatial 위치를 결정한 결과 - 채도가 극단적인 이유: mask_density=0.032 (전체 픽셀의 3.2%만 사용) + lambda_norm=100 (트리거 norm 강한 페널티) → 작은 영역에 강한 신호를 담아야 하므로 고채도 RGB 극단값이 최적 - 3행(cross)은 다른 입력의 trigger를 갖다 붙인 샘플 — 트리거 위치/패턴이 bd와 같은 입력에 어울리지 않게 misaligned되어 있음. 이 cross 샘플은 학습 시 원래 라벨로 분류되도록 강제됨 → 모델이 "특정 입력-트리거 쌍"만 백도어로 작동하게 lock-in

Stealth 개념의 차이: - WaNet stealth: 픽셀 차이 거의 0 (육안 무관) - Input-aware stealth: 트리거가 작고 클래스/위치가 가변 (눈에 보이지만 무시할 만한 크기)

같은 0.94+ ASR을 달성하는 두 attack이지만, **imperceptibility** 기준에서는 **WaNet이 명확히 우위**. Input-aware는 imperceptibility 일부를 동적 트리거 메커니즘에 양보한 셈.

→ WaNet (0.914 / 0.951 / 0.048)과 헤드라인 수치 거의 동일. 두 attack 모두 같은 stealth 목표 도달.

4. 실험 2: 방어 평가 (5종)

각 방어를 동일 셋팅(num_workers 0, pin_memory False)으로 실행.

방어	카테고리	핵심 가정 / 동작
FT	Fine-tuning	깨끗한 데이터로 재학습
NAD	Distillation	FT teacher → attention map 증류
ANP	Pruning	adversarial perturbation으로 백도어 뉴런 찾아 제거
ABL	Isolation + unlearning	low-loss outlier 격리 → finetuning → gradient ascent unlearning
NC	Trigger reverse-eng.	minimum-L1 reverse trigger → MAD anomaly → 미세조정

4.1 방어별 결과

FT

	공격 후	FT 후
ACC	0.9106	0.9265
ASR	0.9449	0.2127
RA	0.0524	0.7437

→ asr 95% → 21%로 감소. WaNet (FT 후 asr 0.17)보다 4%p 더 견딤. per-sample trigger가 단순 재학습에 약간 더 강함.

NAD

	공격 후	NAD 후
ACC	0.9106	0.9260
ASR	0.9449	0.5473
RA	0.0524	0.4321

→ asr 95% → 55% (절반밖에 감소 안 됨). **WaNet (NAD 후 asr 0.087) 대비 6배 강하게 견딤**. NAD에 대한 Input-aware의 robustness는 이 보고서의 가장 큰 발견.

ANP (기본 threshold)

	공격 후	ANP 후
ACC	0.9106	0.8634
ASR	0.9449	0.0050
RA	0.0524	0.8436

→ ANP는 매우 효과적. 단 ACC 5%p 손해. (Pareto knee 결과는 §5.1 참조)

ABL (소규모: tuning 10 / finetuning 20 / unlearning 10)

	공격 후	ABL 후
ACC	0.9106	0.5964
ASR	0.9449	0.9899
RA	0.0524	0.0066

→ **완전 실패**. ABL이 unlearning 단계에서 모델을 collapse 시키면서 ASR을 떨어뜨리지도 못함. WaNet ABL 소규모 결과(ACC 0.84 / ASR 0.59)와 비교해도 훨씬 나쁨. Input-aware의 per-sample 트리거가 ABL의 "low-loss outlier = 백도어 샘플" heuristic을 깨뜨려 잘못된 샘플을 격리한 것으로 추정.

NC — 실패


	공격 후	NC 후
ACC	0.9106	0.9120
ASR	0.9449	0.9844
RA	0.0524	0.0147

NC가 reverse-engineering한 클래스별 트리거 L1 norm:

117.72, 111.47, 102.16, 103.10, 108.00, 114.39, 137.00, 128.66, 101.49, 121.63

모든 클래스가 101~137 범위로 평탄 → target=0 (airplane, L1=117.72) anomaly 검출 불가 → unlearning 미수행. WaNet의 동일 결과(91~139)와 같은 패턴으로 **NC가 가정하는 "작은 고정 패턴" 가설이 두 stealthy attack 모두에 부적합함**을 재확인.


4.2 종합 비교 (6 그룹 막대)



5. 정량 분석

5.1 ANP threshold sweep — Pareto frontier

ANP의 mask threshold τ 를 [0.0, 0.9] 구간에서 sweep.




t	ACC	ASR	RA
0.00	0.910	0.858	(init)
0.05	0.912	0.044	—
0.20	0.914	0.039	—
0.35	0.916	0.016	—
0.45 (knee)	0.9102	0.0109	0.8848
0.55	0.895	0.015	—
0.65	0.863	0.005	—
0.70	0.811	0.0003	—
0.90	0.540	0.000	—

관찰: - $t \in [0.05, 0.65]$ 구간이 ACC 거의 무손실(≥ 0.86)이면서 $ASR < 0.05$ 인 wide flat region. WaNet과 거의 동일한 형태의 γ 모양 Pareto frontier - Knee $t=0.45$: **ACC 0.9102 / ASR 0.0109 / RA 0.8848** — 본 보고서 §4.1의 ANP 단일 실행값(ACC 0.8634)보다 더 좋은 trade-off - **WaNet의 ANP knee와 거의 동일** (WaNet: ACC 0.9064 / ASR 0.0114). 두 attack 모두 ANP에 비슷한 수준으로 깨진다는 정량 증거

5.2 Layer-wise weight delta — attack vs NAD

NAD 정화가 네트워크의 어느 부분을 수정했는지 stage 단위로 측정.



stage	rel ΔW (Input-aware)	rel ΔW (WaNet, 참고)
conv1	0.038	0.044
layer1	0.031	0.039
layer2	0.035	0.047
layer3	0.038	0.049
layer4	0.024	0.036
linear	0.020	0.029

Top-20 most-changed parameters (Input-aware): 1. `layer4.1.bn2.bias` — 0.144 (1위, WaNet에서도 1 위였음. 두 attack 공통) 2. `layer3.0.conv2.weight` — 0.058 3. `layer3.1.conv1.weight` — 0.053 4. ... 이어서 conv weight, BN bias 다수

관찰: - 모든 stage가 WaNet 대비 변화량이 작다 (예: layer4 0.024 vs 0.036). NAD가 Input-aware에서 가중치를 덜 수정했음 → §4.1 NAD 결과가 ASR 0.55로 부분 정확도에 그친 것과 일관 - **Top-1 파라미터가 두 attack 모두 `layer4.1.bn2.bias` 로 동일.** 분류 헤드 직전의 BN bias가 백도어 결정 경로의 공통 핵심 노드 - `linear` (분류 헤드) 변화가 가장 작다는 패턴도 두 attack 공통 (0.020 vs 0.029). 백도어는 분류 헤드가 아닌 중-후반 conv stage + BN bias에 분산 형성

5.3 ABL 실패 메커니즘 분석

ABL은 가정: 백도어 샘플은 학습 도중 비정상적으로 낮은 loss를 보임 → 그것만 격리해서 unlearn.

WaNet에서는 고정 워핑이라 backbone이 "워핑된 = 백도어" 매핑을 빠르게 학습 → 백도어 샘플 loss가 정말로 낮음 → ABL의 low-loss 격리가 어느 정도 맞음.

Input-aware에서는 generator가 매번 다른 trigger를 만들기 때문에 backbone이 "이 특정 패턴 = 백도어"라고 외울 수 없음 → 백도어 샘플 loss가 clean과 별로 다르지 않음 → ABL이 잘못된 샘플 500개를 격리 → unlearning 단계에서 정상 representation을 unlearn 시키며 model collapse.

이는 본 실험에서 ABL이 unlearning 직후 train_acc 0.10 (10클래스 random), test_acc 0.60, test_asr 0.99를 보인 패턴과 일관.


6. 시각화 분석

PreAct-ResNet18의 동일 layer (`layer4.1.conv2`)에서 공격 모델과 NAD 정화 모델을 비교.


6.1 t-SNE — feature 공간 분포

각 색은 클래스(0~9), 검정색 ★ = Poisoned 샘플 (bd_test).

공격 모델



NAD 방어 후




관찰 (WaNet과 명확한 차이): - 공격 모델에서 **poisoned** 점들이 중앙에 매우 **cohesive**한 **cluster**를 형성 — 모든 입력에 대해 generator가 만든 트리거가 같은 feature-space 위치로 수렴. WaNet 공격 모델에서는 poisoned 점이 클러스터 사이에 흩어져 있었음 (§WaNet 보고서 §5.1) - **NAD 후엔 poisoned 점이 여러 클러스터로 분산** — NAD가 cohesive backdoor representation을 일부 깨뜨렸음. 단 완전 정화는 아님 (NAD ASR 0.547과 일관) - Input-aware의 동적 *per-sample* 트리거가 feature-space에서는 정적 *cluster*를 만든다는 발견 — trigger 다양성과 feature 다양성이 분리되어 있음

6.2 Grad-CAM — 모델이 보는 영역

위쪽 행 2개: clean 샘플 (Dog, Horse). 아래쪽 행 2개: Input-aware 백도어 샘플 (Cat → 트리거 적용).

공격 모델 Grad-CAM



NAD 방어 후 Grad-CAM




	clean Dog	clean Horse	bd Cat #1	bd Cat #2
공격 모델	Cat 88% (오)	Horse 99% ✓	Airplane 98% ✗	Airplane 99% ✗
NAD 후	Cat 89% (오)	Horse 99% ✓	Airplane 83% ✗	Airplane 96% ✗

관찰: - bd 이미지에 눈에 보이는 작은 **colored line/dot 패턴**(cyan/magenta/yellow 줄무늬)이 가장자리나 객체 위에 존재. **WaNet의 invisible 워핑과 가장 큰 시각적 차이** — Input-aware는 imperceptibility 일부를 동적 트리거에 양보 - Grad-CAM heatmap은 두 모델 모두 객체 중심 + 패턴이 있는 영역에 분산. 공격 모델은 같은 영역을 보고도 Airplane으로 분류 - **NAD 후에도 이 특정 샘플들은 여전히 Airplane으로 오분류** (이 sample들은 NAD가 정확하지 못한 ASR 0.55의 영역에 속함) — WaNet NAD에서 동일 샘플들이 Cat으로 회복된 것과 대조

6.3 Frequency saliency — 주파수 영역

위쪽: clean (Deer, Truck). 아래쪽: 백도어 (Bird → Airplane 99.56%, Cat → Airplane 99.77%).




관찰: - 백도어 입력의 colored line 트리거가 이미지에서 명확히 보이지만, 주파수 saliency map은 clean과 비슷한 분포 (red dominant + 산발적 blue) - WaNet의 frequency 분석에서는 가장자리/모서리에 saliency가 약하게 응집했으나, Input-aware는 그런 패턴 없음 → 동적 per-sample 트리거가 spatial 위치를 자유롭게 옮기기 때문에 *일관된 frequency 시그니처*가 존재하지 않음 - 결론: 주파수 영역만으로 Input-aware 백도어를 식별하기는 어려움. WaNet보다 더 frequency-agnostic

6.4 Confusion Matrix — bd_test에서 분류 결과


bd_test의 True label은 모두 target=0(airplane)으로 변경되어 있어, airplane 행만 의미 있는 데이터 보유.

공격 모델 CM



→ airplane 행: **0.98**이 airplane으로 예측 = ASR 98%. 백도어가 매우 강하고 일관됨.

NAD 방어 후 CM



→ airplane 행: **0.55 airplane** (= NAD 후 ASR 0.547), 나머지 45%는 9개 클래스로 흩어짐 (horse 0.09, truck 0.08, automobile 0.06 등).

WaNet과의 차이: - WaNet NAD CM은 airplane 행이 9~14% **거의 균등 분포** — 백도어 거의 완전 무력화 - Input-aware NAD CM은 airplane이 여전히 0.55로 **최대값** — 백도어 정렬이 절반은 남아있음 - 시각적으로 두 stealthy attack의 **NAD 견딤 차이**가 가장 명확하게 드러나는 그림

7. WaNet vs Input-aware 종합 비교

같은 저자의 두 attack을 동일 셋팅(100 epoch, CIFAR-10, PreActResNet18, 동일 hparam 골격)에서 평가한 결과.

6.1 공격 효과 (방어 없이)

지표	WaNet	Input-aware
clean ACC	0.914	0.911
ASR	0.951	0.945
RA	0.048	0.052

→ 거의 동일. 두 attack 모두 stealth 목표 도달.

6.2 방어 견딤 (ASR after defense, 낮을수록 방어 효과 큼)

방어	WaNet ASR	Input-aware ASR	차이
FT	0.168	0.213	+4.5%p
NAD	0.087	0.547	+46.0%p ← 가장 큰 차이
ANP (default)	0.010	0.005	-0.5%p
ANP knee (t=0.45)	0.011	0.011	동일
ABL (소규모)	0.586	0.990	+40.4%p (model collapse)
NC	0.951 (실패)	0.984 (실패)	둘 다 실패

6.3 핵심 발견 4가지

1. **NC는 두 attack 모두 무력화** — reverse trigger L1 분포가 모든 클래스에서 평탄(WaNet 91~139, Input-aware 101~137) → MAD anomaly 미검출. NC가 가정하는 "작은 고정 패턴" 가설은 **stealthy attack 일** 반에 부적합함을 두 사례로 확인
2. **NAD는 Input-aware에 6배 더 약함** (ASR 0.087 → 0.547). 가설: WaNet의 고정 워핑은 teacher의 attention map에서 단일 패턴으로 학습 가능하나, Input-aware의 per-sample 동적 트리거는 teacher가 백도어 attention을 *하나의 일관된 패턴*으로 포착하지 못해 student 증류 효과 약화. §5.2의 layer-wise weight delta가 이를 지지 — NAD가 Input-aware에서 가중치를 더 적게 수정했음
3. **ANP는 두 attack 모두 동등하게 갸** (knee 모두 ACC 0.91 / ASR 0.011). 백도어 형성 위치(중-후반 conv stage + BN bias)와 마스크 가능한 뉴런 수가 두 attack에서 비슷하다는 정량 증거 (Top-1 파라미터도 둘 다 `layer4.1.bn2.bias`)
4. **ABL은 Input-aware에 완전 실패** (model collapse). 가정 ("*백도어 샘플 = low-loss outlier*")이 per-sample dynamic trigger에서 무너짐 → 잘못된 샘플을 격리해 정상 표현까지 unlearn. WaNet에서는 적어도 부분 효과(asr 0.95 → 0.59)가 있었던 반면 Input-aware에선 model이 무너지며 asr 변화 없음

8. 결론

1. 두 attack은 헤드라인이 거의 동일하나 방어 견딤은 완전히 다름 — 같은 ACC/ASR을 보이는 백도어가 본질적으로 다른 강건성을 가질 수 있음

2. **트리거의 동적 여부가 NAD / ABL의 효과를 가른다** — 고정 트리거(WaNet)는 attention 패턴을 한 가지로 학습시키고 백도어 샘플의 loss를 일관되게 낮춤 → NAD가 attention에서 식별 가능, ABL이 격리 가능. 동적 트리거(Input-aware)는 둘 다 깨뜨림
 3. **ANP는 트리거 형태와 무관하게 효과적** — 두 attack 모두 mask threshold sweep의 μ 모양 frontier가 거의 동일. 백도어 학습된 뉴런의 수와 위치는 트리거 동적 여부에 의존하지 않음
 4. **NC의 한계는 stealthy attack 일반에 적용** — 워핑이든 generator든 "작은 고정 패턴"이 아니면 reverse-engineering이 정상 클래스 트리거와 구별 안 됨
 5. **공통 백도어 노드 `layer4.1.bn2.bias`** — 두 stealthy attack이 동일한 단일 파라미터를 백도어 결정의 핵심으로 사용. BN affine 파라미터의 백도어 거점 역할은 attack-agnostic 현상으로 보임
-

부록: 본 실험 산출물

- 학습된 모델 ckpt + 메타 (5종 방어 결과 포함)
- 정량 분석 PNG 3종: ANP threshold sweep, layer-wise weight delta, defense_compare bar chart
- epoch별 메트릭 csv 일체