

BackdoorBench 코드 변경사항 보고서

LF (Low Frequency) 공격 실험 — 조수빈

2026. 05. 30 · Google Colab 환경 호환성 패치 · 알고리즘 변경 없음

1. 개요

BackdoorBench 원본 코드는 Python 3.8 / PyTorch 1.x / NumPy 1.x 기준으로 작성되어 있습니다. Google Colab 최신 환경(Python 3.12, PyTorch 2.10, NumPy 2.x)에서 실행하기 위해 3 건의 호환성 패치를 적용했습니다.

※ 공격/방어 알고리즘 자체는 전혀 변경하지 않았습니다. 모든 수정은 API 이름 변경이나 삭제된 별칭(alias) 대응입니다.

2. 변경 파일 요약

#	파일	변경 내용	이유
1	utils/save_load_attack.py	torch.load()에 weights_only=False 추가	PyTorch 2.6+ 기본값 변경
2	utils/trainer_cls.py	np.infty → np.inf	NumPy 2.0 에서 np.infty 삭제
3	utils/bd_img_transform/patch.py	np.float → float	NumPy 2.0 에서 np.float 삭제

3. 변경 상세

변경 1: torch.load() 호환성

PyTorch 2.6 부터 torch.load()의 기본값이 weights_only=True 로 변경되었습니다.

BackdoorBench 의 .pt 파일은 모델 가중치뿐 아니라 데이터셋 메타정보도 포함하고 있어 weights_only=False 가 필요합니다.

파일: utils/save_load_attack.py — line 198

변경 전

```
load_file = torch.load(save_path)
```

변경 후

```
load_file = torch.load(save_path, weights_only=False)
```

변경 2: np.infty → np.inf

NumPy 2.0 에서 np.infty 별칭이 삭제되었습니다. np.inf 는 동일한 값(float("inf"))이며 모든 NumPy 버전에서 동작합니다.

파일: utils/trainer_cls.py — line 754~755

변경 전

```
all_min = np.infty  
all_max = -np.infty
```

변경 후

```
all_min = np.inf  
all_max = -np.inf
```

변경 3: np.float → float

NumPy 2.0 에서 np.float 별칭이 삭제되었습니다. Python 내장 float 과 동일한 타입이었으므로 그대로 교체합니다. 이 파일은 LF 공격의 additive trigger 를 이미지에 적용할 때 사용됩니다.

파일: utils/bd_img_transform/patch.py — line 56

변경 전

```
self.trigger_array = trigger_array.astype(np.float)
```

변경 후

```
self.trigger_array = trigger_array.astype(float)
```

파일: utils/bd_img_transform/patch.py — line 62

변경 전

```
return np.clip(img.astype(np.float) + self.trigger_array, 0, 255).astype(np.uint8)
```

변경 후

```
return np.clip(img.astype(float) + self.trigger_array, 0, 255).astype(np.uint8)
```

4. 패치 적용 방법 (sed 명령어)

Colab 노트북의 셀 5 에서 아래 명령어로 일괄 적용합니다:

```
# PyTorch 2.6+ torch.load 대응
sed -i 's/torch.load(save_path)/torch.load(save_path, weights_only=False)/g'
    ./utils/save_load_attack.py
sed -i 's/torch.load(load_path)/torch.load(load_path, weights_only=False)/g'
    ./utils/save_load_attack.py

# NumPy 2.x np.infty 대응
sed -i 's/np.infty/np.inf/g' ./utils/trainer_cls.py

# NumPy 2.x np.float 대응
sed -i 's/np.float/float/g' ./utils/bd_img_transform/patch.py
```

5. 체크포인트 파일 목록

방어 기법 5 종(FT, NAD, ANP, ABL, NC)으로 통일.

파일명	내용	용량
LF_attack_result.pt	공격 모델 (백도어 삽입)	~47MB
LF_defense_FT(Fine-tuning)_result.pt	FT 방어 후 모델	~44MB
LF_defense_NAD(Neural_Attention_ Distillation)_result.pt	NAD 방어 후 모델	~44MB
LF_defense_ANP(Adversarial_Neuron_ Pruning)_result.pt	ANP 방어 후 모델	~44MB

LF_defense_ABL(Anti-Backdoor_Learning)_result.pt	ABL 방어 후 모델	~44MB
LF_defense_NC(Neural_Cleanse)_result.pt	NC 방어 후 모델	~44MB

6. 실험 환경

플랫폼 / GPU	Google Colab / Tesla T4
Python / PyTorch	3.12 / 2.10.0 + cu128
NumPy	2.x
공격 기법	Low Frequency (LF)
데이터셋 / 모델	CIFAR-10 / PreAct-ResNet18
Target class	0 (airplane)
Poison ratio	0.1
Epochs	100